

# Fundamentos Estatísticos para Ciência dos Dados

## Introdução ao curso

Renato Martins Assunção

DCC, UFMG - 2017



# Diferença entre probabilidade e estatística

- Probabilidade: um ramo da matemática pura.

# Diferença entre probabilidade e estatística

- Probabilidade: um ramo da matemática pura.
- Ela permite fazer cálculos matemáticos sobre fenômenos aleatórios.

# Diferença entre probabilidade e estatística

- Probabilidade: um ramo da matemática pura.
- Ela permite fazer cálculos matemáticos sobre fenômenos aleatórios.
- Não precisa de dados estatísticos.

# Diferença entre probabilidade e estatística

- Probabilidade: um ramo da matemática pura.
- Ela permite fazer cálculos matemáticos sobre fenômenos aleatórios.
- Não precisa de dados estatísticos.
- Como funciona: estabeleça um modelo probabilístico.

# Diferença entre probabilidade e estatística

- Probabilidade: um ramo da matemática pura.
- Ela permite fazer cálculos matemáticos sobre fenômenos aleatórios.
- Não precisa de dados estatísticos.
- Como funciona: estabeleça um modelo probabilístico.
- A seguir, calcule probabilidades de eventos de interesse.

# Sequência mais longa

- Jogue moeda para cima 100 vezes

# Sequência mais longa

- Jogue moeda para cima 100 vezes
- Qual a chance de observar uma sequência de 8 ou mais caras em seguida?

# Sequência mais longa

- Jogue moeda para cima 100 vezes
- Qual a chance de observar uma sequência de 8 ou mais caras em seguida?
- É um cálculo matemático.
- Não precisa realizar o experimento físico para calcular as chances.

# Sequência mais longa

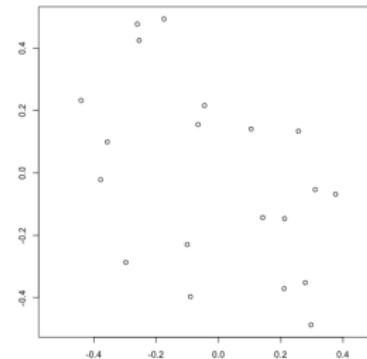
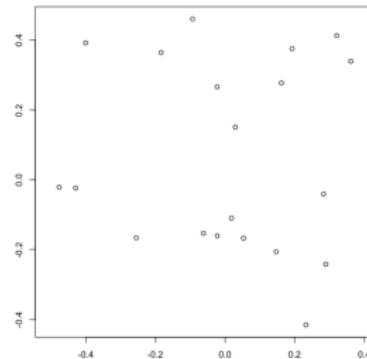
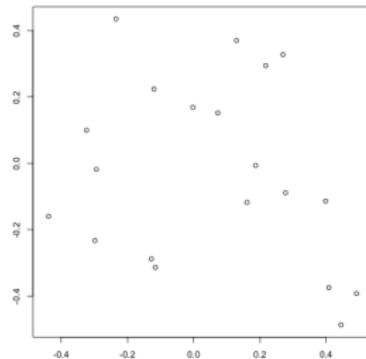
- Jogue moeda para cima 100 vezes
- Qual a chance de observar uma sequência de 8 ou mais caras em seguida?
- É um cálculo matemático.
- Não precisa realizar o experimento físico para calcular as chances.
- Mas para quê isto?
- Hot hand em esportes.
- Pontos sucessivos para time A ou B como se fossem cara-coroa de uma moeda.
- Mas probabilidade de A varia ao longo do jogo: às vezes, fica quente.
- Isto é verdade? Até que ponto esta variação pode ocorrer?

# Probabilidade: modelo espacial 1

- $n$  pontos são jogados completamente ao acaso no quadrado de área 1 centrado na origem  $(0, 0)$ .

# Probabilidade: modelo espacial 1

- $n$  pontos são jogados completamente ao acaso no quadrado de área 1 centrado na origem  $(0, 0)$ .
- Veja três realizações independentes deste experimento.



# Probabilidade: modelo espacial 1

- Qual a probabilidade  $\mathbb{P}_1(r)$  de que não exista nenhum ponto num raio  $r$  em torno da origem  $(0, 0)$ ?

# Probabilidade: modelo espacial 1

- Qual a probabilidade  $\mathbb{P}_1(r)$  de que não exista nenhum ponto num raio  $r$  em torno da origem  $(0, 0)$ ?
- Se  $r \approx 0$ ,  $\mathbb{P}_1(r)$  deve ser próxima de 1.

# Probabilidade: modelo espacial 1

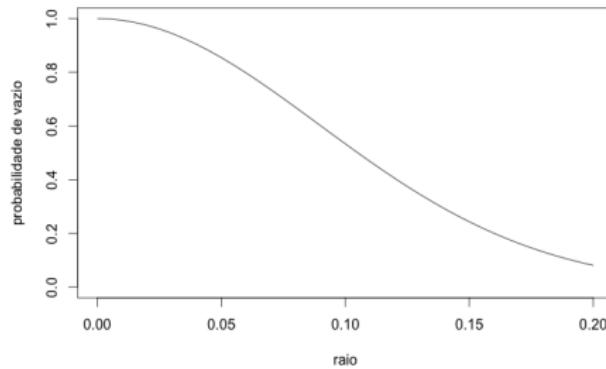
- Qual a probabilidade  $\mathbb{P}_1(r)$  de que não exista nenhum ponto num raio  $r$  em torno da origem  $(0, 0)$ ?
- Se  $r \approx 0$ ,  $\mathbb{P}_1(r)$  deve ser próxima de 1.
- Quando  $r$  aumenta,  $\mathbb{P}_1(r)$  deve decrescer para zero.

# Probabilidade: modelo espacial 1

- Qual a probabilidade  $\mathbb{P}_1(r)$  de que não exista nenhum ponto num raio  $r$  em torno da origem  $(0, 0)$ ?
- Se  $r \approx 0$ ,  $\mathbb{P}_1(r)$  deve ser próxima de 1.
- Quando  $r$  aumenta,  $\mathbb{P}_1(r)$  deve decrescer para zero.
- Pode-se mostrar que  $\mathbb{P}_1(r)$  é aproximadamente igual a  $\exp(-n\pi r^2)$ .

# Probabilidade: modelo espacial 1

- Qual a probabilidade  $\mathbb{P}_1(r)$  de que não exista nenhum ponto num raio  $r$  em torno da origem  $(0, 0)$ ?
- Se  $r \approx 0$ ,  $\mathbb{P}_1(r)$  deve ser próxima de 1.
- Quando  $r$  aumenta,  $\mathbb{P}_1(r)$  deve decrescer para zero.
- Pode-se mostrar que  $\mathbb{P}_1(r)$  é aproximadamente igual a  $\exp(-n\pi r^2)$ .  
Gráfico com  $n = 20$ .



# Probabilidade: modelo espacial 1

- A probabilidade  $\mathbb{P}_1(r)$  é calculada SEM DADOS.

# Probabilidade: modelo espacial 1

- A probabilidade  $\mathbb{P}_1(r)$  é calculada SEM DADOS.
- É um cálculo matemático.

# Probabilidade: modelo espacial 1

- A probabilidade  $\mathbb{P}_1(r)$  é calculada SEM DADOS.
- É um cálculo matemático.
- A figura com três configurações de pontos é apenas ilustrativa.

# Probabilidade: modelo espacial 1

- A probabilidade  $\mathbb{P}_1(r)$  é calculada SEM DADOS.
- É um cálculo matemático.
- A figura com três configurações de pontos é apenas ilustrativa. Ela não foi usada no cálculo de  $\mathbb{P}_1(r)$ .

# Probabilidade: modelo espacial 1

- A probabilidade  $\mathbb{P}_1(r)$  é calculada SEM DADOS.
- É um cálculo matemático.
- A figura com três configurações de pontos é apenas ilustrativa. Ela não foi usada no cálculo de  $\mathbb{P}_1(r)$ .
- Para este modelo de pontos aleatórios, várias outras probabilidades podem ser calculadas.

# Probabilidade: modelo espacial 1

- A probabilidade  $\mathbb{P}_1(r)$  é calculada SEM DADOS.
- É um cálculo matemático.
- A figura com três configurações de pontos é apenas ilustrativa. Ela não foi usada no cálculo de  $\mathbb{P}_1(r)$ .
- Para este modelo de pontos aleatórios, várias outras probabilidades podem ser calculadas.
- Por exemplo, qual a probabilidade de que existam pelo menos 2 pontos numa certa região de área  $\alpha$ ?

# Probabilidade: modelo espacial 1

- A probabilidade  $\mathbb{P}_1(r)$  é calculada SEM DADOS.
- É um cálculo matemático.
- A figura com três configurações de pontos é apenas ilustrativa. Ela não foi usada no cálculo de  $\mathbb{P}_1(r)$ .
- Para este modelo de pontos aleatórios, várias outras probabilidades podem ser calculadas.
- Por exemplo, qual a probabilidade de que existam pelo menos 2 pontos numa certa região de área  $\alpha$ ?
- É aproximadamente

$$1 - e^{-n\alpha} (1 + n\alpha)$$

- Não é preciso coletar nenhum dado para fazer estes cálculos.

# Mudando o modelo probabilístico

- Outro modelo probabilístico para geração de pontos no quadrado leva a resultados bem diferentes no cálculo de probabilidade.

# Mudando o modelo probabilístico

- Outro modelo probabilístico para geração de pontos no quadrado leva a resultados bem diferentes no cálculo de probabilidade.
- Por exemplo, suponha que apenas 5 pontos-pais são jogados completamente ao acaso no quadrado de área 1 centrado na origem  $(0, 0)$ .

# Mudando o modelo probabilístico

- Outro modelo probabilístico para geração de pontos no quadrado leva a resultados bem diferentes no cálculo de probabilidade.
- Por exemplo, suponha que apenas 5 pontos-pais são jogados completamente ao acaso no quadrado de área 1 centrado na origem  $(0, 0)$ .
- A seguir, cada ponto-pai gera 4 pontos-filhos de forma que temos 20 pontos-filho no final.

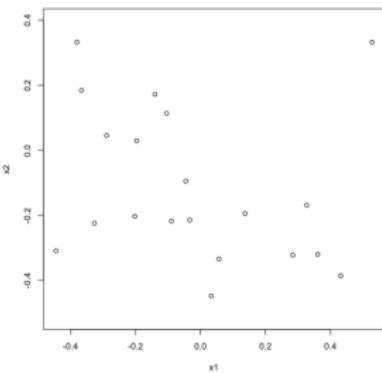
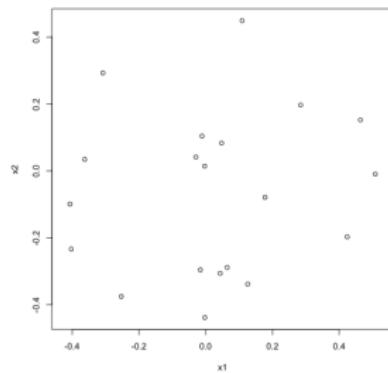
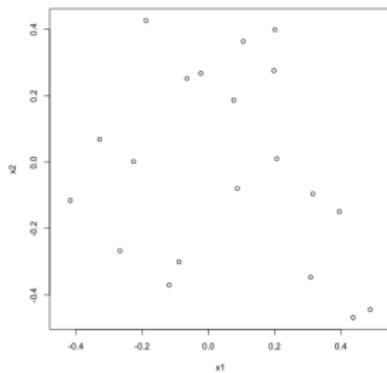
## Mudando o modelo probabilístico

- Outro modelo probabilístico para geração de pontos no quadrado leva a resultados bem diferentes no cálculo de probabilidade.
- Por exemplo, suponha que apenas 5 pontos-pais são jogados completamente ao acaso no quadrado de área 1 centrado na origem  $(0, 0)$ .
- A seguir, cada ponto-pai gera 4 pontos-filhos de forma que temos 20 pontos-filho no final.
- Os filhos espalham-se ao acaso em torno dos pais até uma distância máxima de 0.1

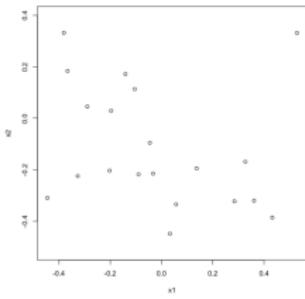
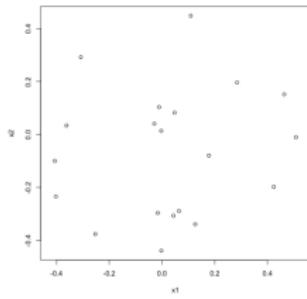
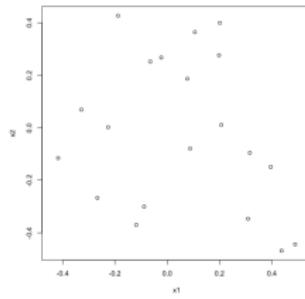
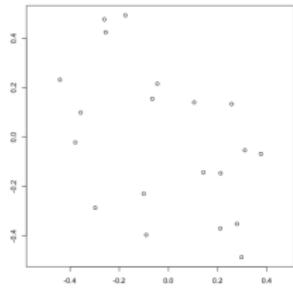
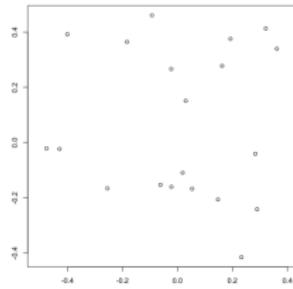
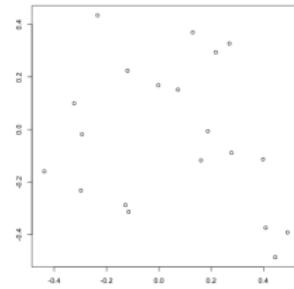
## Mudando o modelo probabilístico

- Outro modelo probabilístico para geração de pontos no quadrado leva a resultados bem diferentes no cálculo de probabilidade.
- Por exemplo, suponha que apenas 5 pontos-pais são jogados completamente ao acaso no quadrado de área 1 centrado na origem  $(0, 0)$ .
- A seguir, cada ponto-pai gera 4 pontos-filhos de forma que temos 20 pontos-filho no final.
- Os filhos espalham-se ao acaso em torno dos pais até uma distância máxima de 0.1
- Considere o padrão espacial dos pontos compostos apenas pelos filhos.

# Probabilidade: modelo espacial 2



# Modelo 1 ( $1^{\text{a}}$ linha) e modelo 2 ( $2^{\text{a}}$ linha)

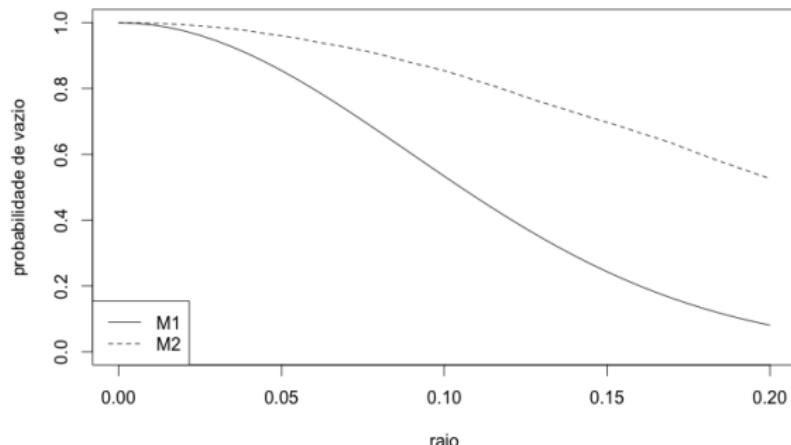


## Probabilidade: modelo espacial 2

- No modelo 2, qual a probabilidade  $\mathbb{P}_2(r)$  de que não exista nenhum ponto num raio  $r$  em torno da origem  $(0, 0)$ ?

## Probabilidade: modelo espacial 2

- No modelo 2, qual a probabilidade  $\mathbb{P}_2(r)$  de que não exista nenhum ponto num raio  $r$  em torno da origem  $(0, 0)$ ?
- Como no modelo 1, temos  $\mathbb{P}_2(r) \approx 1$  e diminuindo para zero quando o raio  $r$  aumenta.
- Mas ela faz isto de forma bem diferente nos dois modelos.



# Estatística: dados, dados, dados...

- Estatística: um ramo da matemática aplicada.

# Estatística: dados, dados, dados...

- Estatística: um ramo da matemática aplicada.
- Precisa de dados estatísticos. O que fazemos com esses dados?

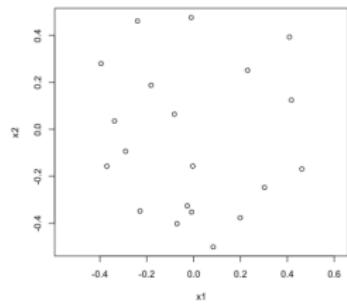
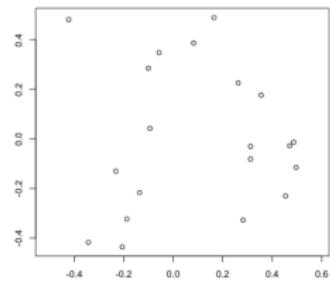
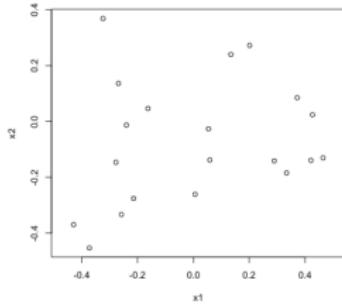
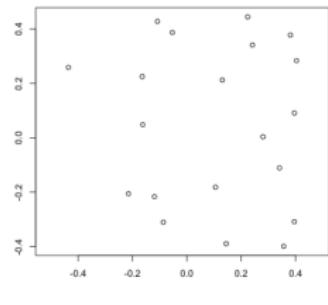
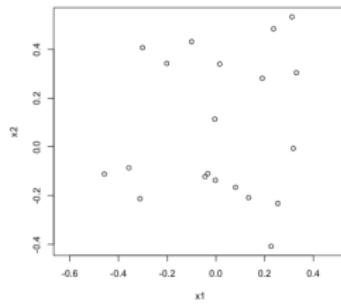
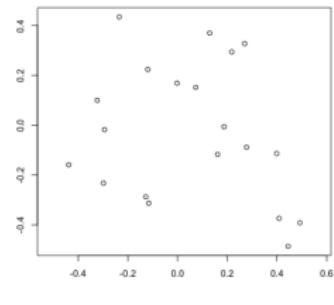
# Estatística: dados, dados, dados...

- Estatística: um ramo da matemática aplicada.
- Precisa de dados estatísticos. O que fazemos com esses dados?
- Procuramos inferir qual foi o modelo probabilístico que gerou os dados observados.

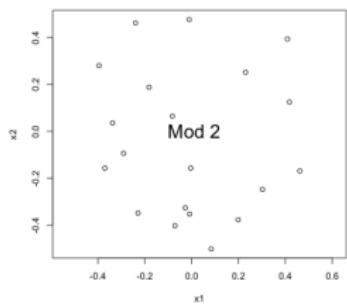
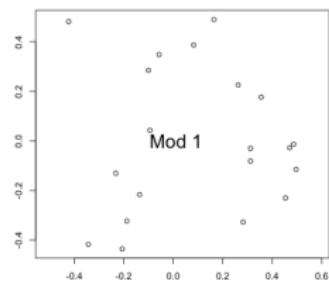
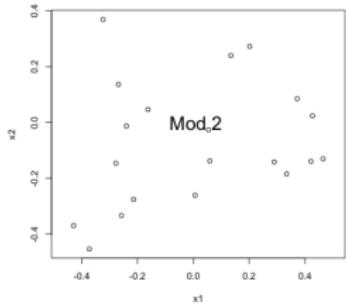
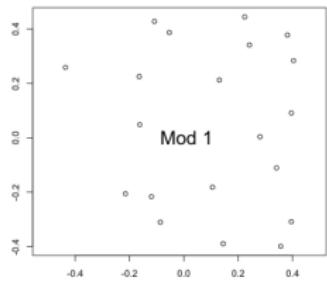
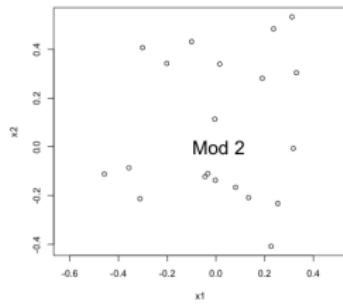
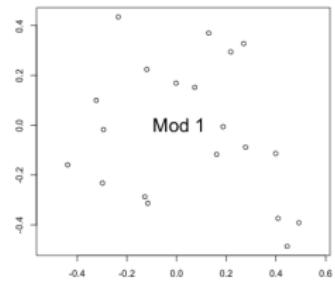
# Estatística: dados, dados, dados...

- Estatística: um ramo da matemática aplicada.
- Precisa de dados estatísticos. O que fazemos com esses dados?
- Procuramos inferir qual foi o modelo probabilístico que gerou os dados observados.
- Qual dos dois modelos gerou cada um dos seis plots a seguir?

# Qual modelo gerou cada plot?



# Identificando os modelos



# Um teste estatístico para discriminar entre os modelos

- Para cada ponto, achei a distância até o seu ponto vizinho mais próximo.

# Um teste estatístico para discriminar entre os modelos

- Para cada ponto, achei a distância até o seu ponto vizinho mais próximo.
- Para vários raios  $r$ , contei a proporção de pontos que tiveram distância menor que  $r$ .

# Um teste estatístico para discriminar entre os modelos

- Para cada ponto, achei a distância até o seu ponto vizinho mais próximo.
- Para vários raios  $r$ , contei a proporção de pontos que tiveram distância menor que  $r$ .
- Por exemplo, para  $r = 0.10$ , obtive a proporção  $G$  de pontos observados que tiveram seu vizinho mais próximo a uma distância menor que 0.10.

# Um teste estatístico para discriminar entre os modelos

- Para cada ponto, achei a distância até o seu ponto vizinho mais próximo.
- Para vários raios  $r$ , contei a proporção de pontos que tiveram distância menor que  $r$ .
- Por exemplo, para  $r = 0.10$ , obtive a proporção  $G$  de pontos observados que tiveram seu vizinho mais próximo a uma distância menor que 0.10.
- Então:

# Um teste estatístico para discriminar entre os modelos

- Para cada ponto, achei a distância até o seu ponto vizinho mais próximo.
- Para vários raios  $r$ , contei a proporção de pontos que tiveram distância menor que  $r$ .
- Por exemplo, para  $r = 0.10$ , obtive a proporção  $G$  de pontos observados que tiveram seu vizinho mais próximo a uma distância menor que 0.10.
- Então:
  - Por meio do cálculo de probabilidades,

# Um teste estatístico para discriminar entre os modelos

- Para cada ponto, achei a distância até o seu ponto vizinho mais próximo.
- Para vários raios  $r$ , contei a proporção de pontos que tiveram distância menor que  $r$ .
- Por exemplo, para  $r = 0.10$ , obtive a proporção  $G$  de pontos observados que tiveram seu vizinho mais próximo a uma distância menor que 0.10.
- Então:
  - Por meio do cálculo de probabilidades,
  - sem usar dados estatísticos,

# Um teste estatístico para discriminar entre os modelos

- Para cada ponto, achei a distância até o seu ponto vizinho mais próximo.
- Para vários raios  $r$ , contei a proporção de pontos que tiveram distância menor que  $r$ .
- Por exemplo, para  $r = 0.10$ , obtive a proporção  $G$  de pontos observados que tiveram seu vizinho mais próximo a uma distância menor que 0.10.
- Então:
  - Por meio do cálculo de probabilidades,
  - sem usar dados estatísticos,
  - com matemática pura (ou por simulação Monte Carlo)

# Um teste estatístico para discriminar entre os modelos

- Para cada ponto, achei a distância até o seu ponto vizinho mais próximo.
- Para vários raios  $r$ , contei a proporção de pontos que tiveram distância menor que  $r$ .
- Por exemplo, para  $r = 0.10$ , obtive a proporção  $G$  de pontos observados que tiveram seu vizinho mais próximo a uma distância menor que 0.10.
- Então:
  - Por meio do cálculo de probabilidades,
  - sem usar dados estatísticos,
  - com matemática pura (ou por simulação Monte Carlo)
  - obtive limites ( $m, M$ ) tais que,

# Um teste estatístico para discriminar entre os modelos

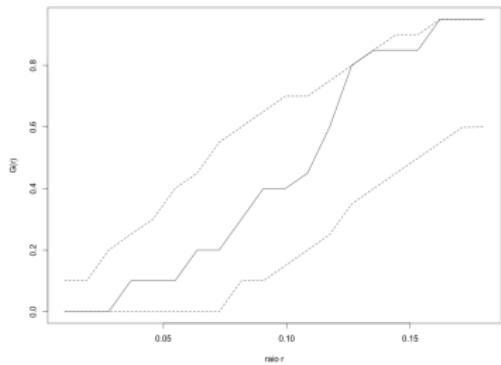
- Para cada ponto, achei a distância até o seu ponto vizinho mais próximo.
- Para vários raios  $r$ , contei a proporção de pontos que tiveram distância menor que  $r$ .
- Por exemplo, para  $r = 0.10$ , obtive a proporção  $G$  de pontos observados que tiveram seu vizinho mais próximo a uma distância menor que 0.10.
- Então:
  - Por meio do cálculo de probabilidades,
  - sem usar dados estatísticos,
  - com matemática pura (ou por simulação Monte Carlo)
  - obtive limites ( $m, M$ ) tais que,
  - se os dados vierem de fato do modelo 1,

# Um teste estatístico para discriminar entre os modelos

- Para cada ponto, achei a distância até o seu ponto vizinho mais próximo.
- Para vários raios  $r$ , contei a proporção de pontos que tiveram distância menor que  $r$ .
- Por exemplo, para  $r = 0.10$ , obtive a proporção  $G$  de pontos observados que tiveram seu vizinho mais próximo a uma distância menor que 0.10.
- Então:
  - Por meio do cálculo de probabilidades,
  - sem usar dados estatísticos,
  - com matemática pura (ou por simulação Monte Carlo)
  - obtive limites ( $m, M$ ) tais que,
  - se os dados vierem de fato do modelo 1,
  - o valor de  $G$  deveria estar entre  $m$  e  $M$  com probabilidade muito alta.
  - Se estiver fora dos limites, o modelo 2 deve ser o correto.

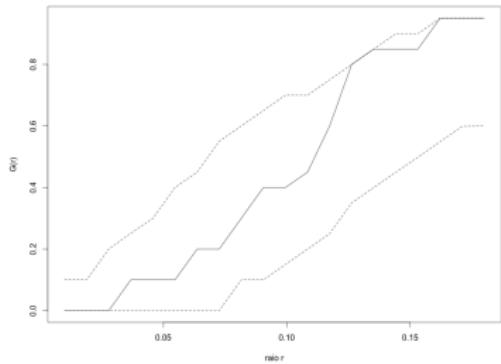
# Um teste estatístico para discriminar entre os modelos

Eixo horizontal: raio  $r$ .



# Um teste estatístico para discriminar entre os modelos

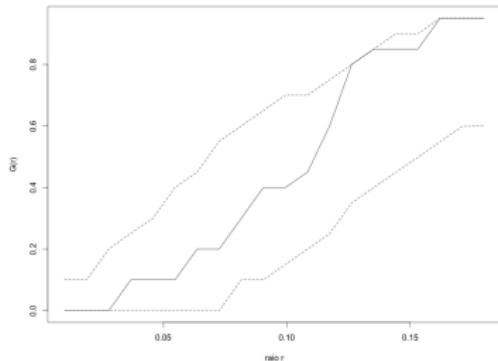
Eixo horizontal: raio  $r$ .



Eixo vertical:  $G(r) = \text{probab da distância ao vizinho mais próximo ser menor que } r$ .

# Um teste estatístico para discriminar entre os modelos

Eixo horizontal: raio  $r$ .

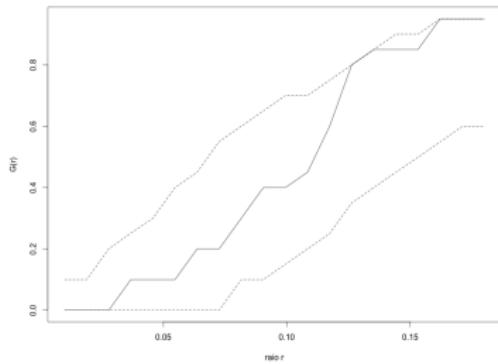


Eixo vertical:  $G(r) = \text{probab da distância ao vizinho mais próximo ser menor que } r$ .

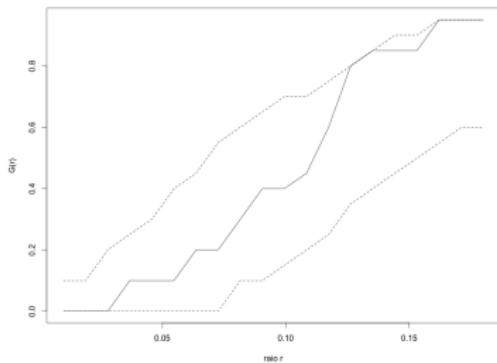
Linhos tracejados:  
limites para  $G(r)$  versus raio  $r$   
CASO MODELO 1 SEJA CORRETO.

# Um teste estatístico para discriminar entre os modelos

Linhas tracejadas foram obtidos com cálculo de probabilidades, sem dados.



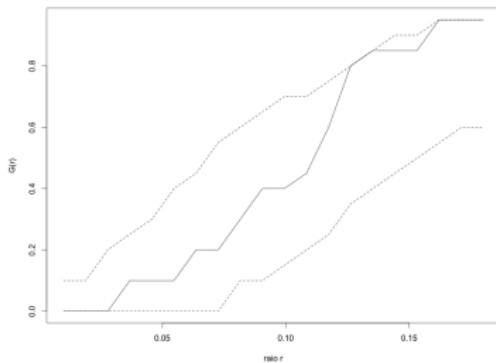
# Um teste estatístico para discriminar entre os modelos



Linhas tracejadas foram obtidos com cálculo de probabilidades, sem dados.

Curva contínua: proporção  $G(r)$  calculada com os dados estatísticos.

# Um teste estatístico para discriminar entre os modelos



Linhas tracejadas foram obtidos com cálculo de probabilidades, sem dados.

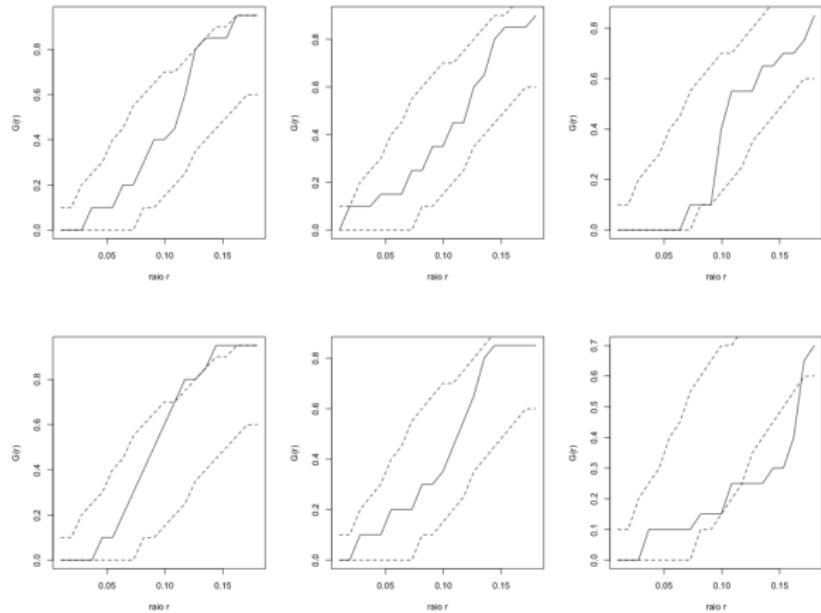
Curva contínua: proporção  $G(r)$  calculada com os dados estatísticos.

Se ficar dentro dos limites, fique com o modelo 1.

Se sair fora dos limites, fique com o modelo 2.

# Decisão: poucos erros

Decisão errada apenas no plot (1, 2) cujos dados são do modelo 2.



# Resumo

- **Probabilidade:** a partir de um modelo probabilístico, calcula matematicamente a probabilidade de diversos eventos (ou dados).

# Resumo

- **Probabilidade:** a partir de um modelo probabilístico, calcula matematicamente a probabilidade de diversos eventos (ou dados).
- Não precisa ter nenhum dado estatístico para isto.

# Resumo

- **Probabilidade:** a partir de um modelo probabilístico, calcula matematicamente a probabilidade de diversos eventos (ou dados).
- Não precisa ter nenhum dado estatístico para isto.
- **Estatística:** possui dados observados, uma tabela de números.

# Resumo

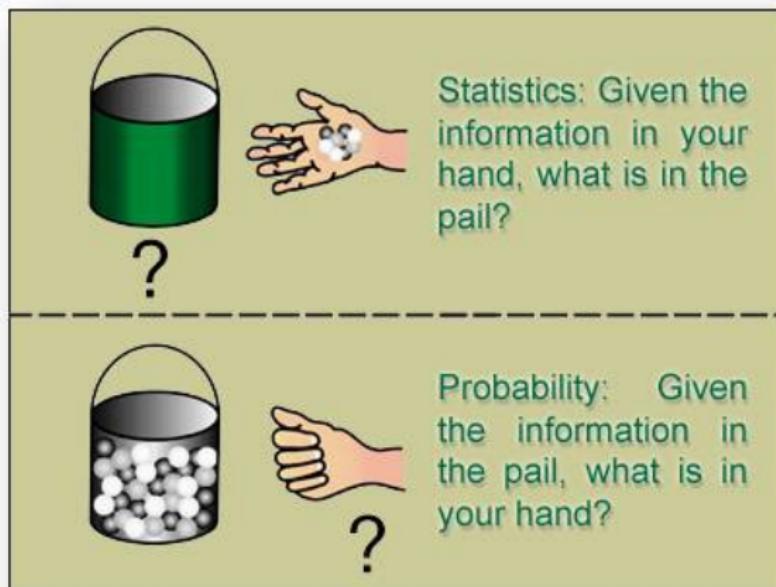
- **Probabilidade:** a partir de um modelo probabilístico, calcula matematicamente a probabilidade de diversos eventos (ou dados).
- Não precisa ter nenhum dado estatístico para isto.
- **Estatística:** possui dados observados, uma tabela de números.
- Deseja descobrir qual foi o modelo probabilístico que gerou estes dados.

# Resumo

- **Probabilidade:** a partir de um modelo probabilístico, calcula matematicamente a probabilidade de diversos eventos (ou dados).
- Não precisa ter nenhum dado estatístico para isto.
- **Estatística:** possui dados observados, uma tabela de números.
- Deseja descobrir qual foi o modelo probabilístico que gerou estes dados.

# Estatística versus probabilidade em imagens

Extraído de [http://herdingcats.typepad.com/my\\_weblog/](http://herdingcats.typepad.com/my_weblog/)



# Risco de crédito: dados e modelo probabilístico

- Clientes solicitam crédito ou tomam empréstimo em bancos.

# Risco de crédito: dados e modelo probabilístico

- Clientes solicitam crédito ou tomam empréstimo em bancos.
- Bancos querem saber, para cada cliente, se ele vai pagar de volta dentro do prazo.

# Risco de crédito: dados e modelo probabilístico

- Clientes solicitam crédito ou tomam empréstimo em bancos.
- Bancos querem saber, para cada cliente, se ele vai pagar de volta dentro do prazo.
- Um modelo de risco de crédito avalia a probabilidade disso ocorrer DADO que o cliente possui certos atributos.

# Risco de crédito: dados e modelo probabilístico

- Clientes solicitam crédito ou tomam empréstimo em bancos.
- Bancos querem saber, para cada cliente, se ele vai pagar de volta dentro do prazo.
- Um modelo de risco de crédito avalia a probabilidade disso ocorrer DADO que o cliente possui certos atributos.
- Se a probabilidade for baixa, ele é um risco potencial e o crédito deveria ser negado.

# Risco de crédito: dados e modelo probabilístico

- Clientes solicitam crédito ou tomam empréstimo em bancos.
- Bancos querem saber, para cada cliente, se ele vai pagar de volta dentro do prazo.
- Um modelo de risco de crédito avalia a probabilidade disso ocorrer DADO que o cliente possui certos atributos.
- Se a probabilidade for baixa, ele é um risco potencial e o crédito deveria ser negado.
- Precisamos de um modelo de probabilidade para fazer estes cálculos.

# Risco de crédito: dados e modelo probabilístico

- Clientes solicitam crédito ou tomam empréstimo em bancos.
- Bancos querem saber, para cada cliente, se ele vai pagar de volta dentro do prazo.
- Um modelo de risco de crédito avalia a probabilidade disso ocorrer DADO que o cliente possui certos atributos.
- Se a probabilidade for baixa, ele é um risco potencial e o crédito deveria ser negado.
- Precisamos de um modelo de probabilidade para fazer estes cálculos.
- Existem muitos (infinitos) modelos possíveis.

# Risco de crédito: dados e modelo probabilístico

- Clientes solicitam crédito ou tomam empréstimo em bancos.
- Bancos querem saber, para cada cliente, se ele vai pagar de volta dentro do prazo.
- Um modelo de risco de crédito avalia a probabilidade disso ocorrer DADO que o cliente possui certos atributos.
- Se a probabilidade for baixa, ele é um risco potencial e o crédito deveria ser negado.
- Precisamos de um modelo de probabilidade para fazer estes cálculos.
- Existem muitos (infinitos) modelos possíveis.
- Alguns são melhores que outros pois conseguem prever melhor que cada cliente vai fazer.

# Risco de crédito: dados e modelo probabilístico

- Clientes solicitam crédito ou tomam empréstimo em bancos.
- Bancos querem saber, para cada cliente, se ele vai pagar de volta dentro do prazo.
- Um modelo de risco de crédito avalia a probabilidade disso ocorrer DADO que o cliente possui certos atributos.
- Se a probabilidade for baixa, ele é um risco potencial e o crédito deveria ser negado.
- Precisamos de um modelo de probabilidade para fazer estes cálculos.
- Existem muitos (infinitos) modelos possíveis.
- Alguns são melhores que outros pois conseguem prever melhor que cada cliente vai fazer.
- Quais os dados para identificar um modelo desses?

## Risco de crédito: dados típicos

- Dados de 1000 clientes de um banco que pegaram empréstimo no passado.

## Risco de crédito: dados típicos

- Dados de 1000 clientes de um banco que pegaram empréstimo no passado.
- Para cada cliente, anota-se uma resposta binária  $Y$ .

## Risco de crédito: dados típicos

- Dados de 1000 clientes de um banco que pegaram empréstimo no passado.
- Para cada cliente, anota-se uma resposta binária  $Y$ .
- $Y = 1$  se pagou de volta no devido tempo.

## Risco de crédito: dados típicos

- Dados de 1000 clientes de um banco que pegaram empréstimo no passado.
- Para cada cliente, anota-se uma resposta binária  $Y$ .
- $Y = 1$  se pagou de volta no devido tempo.
- $Y = 0$  caso contrário.

## Risco de crédito: dados típicos

- Dados de 1000 clientes de um banco que pegaram empréstimo no passado.
- Para cada cliente, anota-se uma resposta binária  $Y$ .
- $Y = 1$  se pagou de volta no devido tempo.
- $Y = 0$  caso contrário.
- Além disso, temos 20 atributos que podem influenciar o comportamento dos clientes.

# Risco de crédito: dados típicos

- Balance of current account
- For how long has been a client (in months)
- Payment of previous credits: *no previous credits/paid back all previous credits; hesitant payment of previous credits; problematic running account.*
- Purpose of credit: *new car; used car; items of furniture; vacation; etc.*
- Amount of credit.
- Value of savings or stocks.
- For how has been employed by current employer (in years).
- Installment in % of available income
- Marital Status
- Sex
- Age, etc.

# Inferindo diretamente a partir dos dados

- Precisamos mesmo de um modelo probabilístico?

# Inferindo diretamente a partir dos dados

- Precisamos mesmo de um modelo probabilístico?
- Nos dias de big data, os dados não respondem tudo?

# Inferindo diretamente a partir dos dados

- Precisamos mesmo de um modelo probabilístico?
- Nos dias de big data, os dados não respondem tudo?
- Afinal, podemos fazer cálculos diretos e simples a partir dos dados diretamente.

# Inferindo diretamente a partir dos dados

- Precisamos mesmo de um modelo probabilístico?
- Nos dias de big data, os dados não respondem tudo?
- Afinal, podemos fazer cálculos diretos e simples a partir dos dados diretamente.
- Por exemplo, qual a probabilidade de um cliente com mais de 60 anos e saldo médio maior que 5 mil reais não pagar o crédito?

# Inferindo diretamente a partir dos dados

- Precisamos mesmo de um modelo probabilístico?
- Nos dias de big data, os dados não respondem tudo?
- Afinal, podemos fazer cálculos diretos e simples a partir dos dados diretamente.
- Por exemplo, qual a probabilidade de um cliente com mais de 60 anos e saldo médio maior que 5 mil reais não pagar o crédito?
- Separe a sub-amostra de clientes com mais de 60 anos e saldo maior que 5 mil.

# Inferindo diretamente a partir dos dados

- Precisamos mesmo de um modelo probabilístico?
- Nos dias de big data, os dados não respondem tudo?
- Afinal, podemos fazer cálculos diretos e simples a partir dos dados diretamente.
- Por exemplo, qual a probabilidade de um cliente com mais de 60 anos e saldo médio maior que 5 mil reais não pagar o crédito?
- Separe a sub-amostra de clientes com mais de 60 anos e saldo maior que 5 mil.
- Se esta sub-amostra não for muito pequena ...

# Inferindo diretamente a partir dos dados

- Precisamos mesmo de um modelo probabilístico?
- Nos dias de big data, os dados não respondem tudo?
- Afinal, podemos fazer cálculos diretos e simples a partir dos dados diretamente.
- Por exemplo, qual a probabilidade de um cliente com mais de 60 anos e saldo médio maior que 5 mil reais não pagar o crédito?
- Separe a sub-amostra de clientes com mais de 60 anos e saldo maior que 5 mil.
- Se esta sub-amostra não for muito pequena ... (digamos, maior que 100 indivíduos) ...

# Inferindo diretamente a partir dos dados

- Precisamos mesmo de um modelo probabilístico?
- Nos dias de big data, os dados não respondem tudo?
- Afinal, podemos fazer cálculos diretos e simples a partir dos dados diretamente.
- Por exemplo, qual a probabilidade de um cliente com mais de 60 anos e saldo médio maior que 5 mil reais não pagar o crédito?
- Separe a sub-amostra de clientes com mais de 60 anos e saldo maior que 5 mil.
- Se esta sub-amostra não for muito pequena ... (digamos, maior que 100 indivíduos) ...
- Dentre os indivíduos dessa sub-amostra, obtenha a proporção dos que não pagaram o crédito.

# Inferindo diretamente a partir dos dados

- Precisamos mesmo de um modelo probabilístico?
- Nos dias de big data, os dados não respondem tudo?
- Afinal, podemos fazer cálculos diretos e simples a partir dos dados diretamente.
- Por exemplo, qual a probabilidade de um cliente com mais de 60 anos e saldo médio maior que 5 mil reais não pagar o crédito?
- Separe a sub-amostra de clientes com mais de 60 anos e saldo maior que 5 mil.
- Se esta sub-amostra não for muito pequena ... (digamos, maior que 100 indivíduos) ...
- Dentre os indivíduos dessa sub-amostra, obtenha a proporção dos que não pagaram o crédito.
- Esta proporção é aproximadamente a probabilidade de não-pagamento.

## Inferindo diretamente a partir dos dados

- Precisamos mesmo de um modelo probabilístico?
- Nos dias de big data, os dados não respondem tudo?
- Afinal, podemos fazer cálculos diretos e simples a partir dos dados diretamente.
- Por exemplo, qual a probabilidade de um cliente com mais de 60 anos e saldo médio maior que 5 mil reais não pagar o crédito?
- Separe a sub-amostra de clientes com mais de 60 anos e saldo maior que 5 mil.
- Se esta sub-amostra não for muito pequena ... (digamos, maior que 100 indivíduos) ...
- Dentre os indivíduos dessa sub-amostra, obtenha a proporção dos que não pagaram o crédito.
- Esta proporção é aproximadamente a probabilidade de não-pagamento.
- Muito simples, apenas contagem no banco de dados.

# Nem sempre é tão simples

- O cliente tem muitos atributos, não apenas idade e saldo médio.

# Nem sempre é tão simples

- O cliente tem muitos atributos, não apenas idade e saldo médio.
- Para cada cliente, temos mais de 15 atributos.

## Nem sempre é tão simples

- O cliente tem muitos atributos, não apenas idade e saldo médio.
- Para cada cliente, temos mais de 15 atributos.
- Se cada atributo possui apenas dois valores possíveis, temos  $2^{15} = 32768$  configurações diferentes de atributos para os clientes.

## Nem sempre é tão simples

- O cliente tem muitos atributos, não apenas idade e saldo médio.
- Para cada cliente, temos mais de 15 atributos.
- Se cada atributo possui apenas dois valores possíveis, temos  $2^{15} = 32768$  configurações diferentes de atributos para os clientes.
- Em cada uma dessas 32 mil configurações possíveis, queremos a probabilidade de não pagamento.

# Nem sempre é tão simples

- O cliente tem muitos atributos, não apenas idade e saldo médio.
- Para cada cliente, temos mais de 15 atributos.
- Se cada atributo possui apenas dois valores possíveis, temos  $2^{15} = 32768$  configurações diferentes de atributos para os clientes.
- Em cada uma dessas 32 mil configurações possíveis, queremos a probabilidade de não pagamento.
- Precisamos de pelo menos uns 100 indivíduos em cada configuração para estimar a probabilidade.

# Nem sempre é tão simples

- O cliente tem muitos atributos, não apenas idade e saldo médio.
- Para cada cliente, temos mais de 15 atributos.
- Se cada atributo possui apenas dois valores possíveis, temos  $2^{15} = 32768$  configurações diferentes de atributos para os clientes.
- Em cada uma dessas 32 mil configurações possíveis, queremos a probabilidade de não pagamento.
- Precisamos de pelo menos uns 100 indivíduos em cada configuração para estimar a probabilidade.
- Isto dá 3276800, ou mais de 3 milhões de indivíduos na base de dados.

## Nem sempre é tão simples

- O cliente tem muitos atributos, não apenas idade e saldo médio.
- Para cada cliente, temos mais de 15 atributos.
- Se cada atributo possui apenas dois valores possíveis, temos  $2^{15} = 32768$  configurações diferentes de atributos para os clientes.
- Em cada uma dessas 32 mil configurações possíveis, queremos a probabilidade de não pagamento.
- Precisamos de pelo menos uns 100 indivíduos em cada configuração para estimar a probabilidade.
- Isto dá 3276800, ou mais de 3 milhões de indivíduos na base de dados.
- Será difícil obter uma base de dados relativamente recentes desta forma para este problema.

## Nem sempre é tão simples

- O cliente tem muitos atributos, não apenas idade e saldo médio.
- Para cada cliente, temos mais de 15 atributos.
- Se cada atributo possui apenas dois valores possíveis, temos  $2^{15} = 32768$  configurações diferentes de atributos para os clientes.
- Em cada uma dessas 32 mil configurações possíveis, queremos a probabilidade de não pagamento.
- Precisamos de pelo menos uns 100 indivíduos em cada configuração para estimar a probabilidade.
- Isto dá 3276800, ou mais de 3 milhões de indivíduos na base de dados.
- Será difícil obter uma base de dados relativamente recentes desta forma para este problema.
- Suponha que não exista na base de dados NENHUM indivíduo com idade  $x$ , saldo  $y$ , etc.

## Nem sempre é tão simples

- O cliente tem muitos atributos, não apenas idade e saldo médio.
- Para cada cliente, temos mais de 15 atributos.
- Se cada atributo possui apenas dois valores possíveis, temos  $2^{15} = 32768$  configurações diferentes de atributos para os clientes.
- Em cada uma dessas 32 mil configurações possíveis, queremos a probabilidade de não pagamento.
- Precisamos de pelo menos uns 100 indivíduos em cada configuração para estimar a probabilidade.
- Isto dá 3276800, ou mais de 3 milhões de indivíduos na base de dados.
- Será difícil obter uma base de dados relativamente recentes desta forma para este problema.
- Suponha que não exista na base de dados NENHUM indivíduo com idade  $x$ , saldo  $y$ , etc.
- Ou quem sabe existam apenas 3 indivíduos com estes atributos.

## Nem sempre é tão simples

- O cliente tem muitos atributos, não apenas idade e saldo médio.
- Para cada cliente, temos mais de 15 atributos.
- Se cada atributo possui apenas dois valores possíveis, temos  $2^{15} = 32768$  configurações diferentes de atributos para os clientes.
- Em cada uma dessas 32 mil configurações possíveis, queremos a probabilidade de não pagamento.
- Precisamos de pelo menos uns 100 indivíduos em cada configuração para estimar a probabilidade.
- Isto dá 3276800, ou mais de 3 milhões de indivíduos na base de dados.
- Será difícil obter uma base de dados relativamente recentes desta forma para este problema.
- Suponha que não exista na base de dados NENHUM indivíduo com idade  $x$ , saldo  $y$ , etc.
- Ou quem sabe existam apenas 3 indivíduos com estes atributos.
- Como estimar bem a probabilidade de não pagamento de um novo cliente com estes atributos?

# Nem sempre é tão simples

- Perdas financeiras associadas com tufões em Taiwan.

# Nem sempre é tão simples

- Perdas financeiras associadas com tufões em Taiwan.
- Qual a probabilidade de ocorrer um tufão causando perda maior que 4 milhões nos próximos 10 anos?
- Zero?

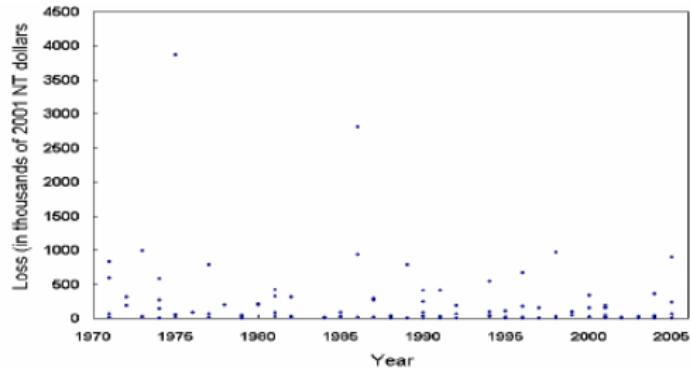


Figure 1. Scatter plot of Taiwan typhoon rice loss

## Mais um exemplo

- Dados  $T_1, T_2, \dots, T_n$ : o tempo de sobrevida de  $n$  pacientes submetidos a um novo tratamento médico.

## Mais um exemplo

- Dados  $T_1, T_2, \dots, T_n$ : o tempo de sobrevida de  $n$  pacientes submetidos a um novo tratamento médico.
- Deseja-se estimar o tempo esperado  $\mathbb{E}(T)$  de sobrevida após o tratamento.

## Mais um exemplo

- Dados  $T_1, T_2, \dots, T_n$ : o tempo de sobrevida de  $n$  pacientes submetidos a um novo tratamento médico.
- Deseja-se estimar o tempo esperado  $\mathbb{E}(T)$  de sobrevida após o tratamento.
- Simples: tire a média aritmética dos  $n$  tempos observados.

## Mais um exemplo

- Dados  $T_1, T_2, \dots, T_n$ : o tempo de sobrevida de  $n$  pacientes submetidos a um novo tratamento médico.
- Deseja-se estimar o tempo esperado  $\mathbb{E}(T)$  de sobrevida após o tratamento.
- Simples: tire a média aritmética dos  $n$  tempos observados.
- Suponha que o experimento precisa fornecer uma estimativa um anos após o início do estudo.

## Mais um exemplo

- Dados  $T_1, T_2, \dots, T_n$ : o tempo de sobrevida de  $n$  pacientes submetidos a um novo tratamento médico.
- Deseja-se estimar o tempo esperado  $\mathbb{E}(T)$  de sobrevida após o tratamento.
- Simples: tire a média aritmética dos  $n$  tempos observados.
- Suponha que o experimento precisa fornecer uma estimativa um anos após o início do estudo.
- Um ano após o estudo, 50% dos pacientes faleceram (e portanto sabe-se o valor de  $T$  para estes indivíduos).

## Mais um exemplo

- Dados  $T_1, T_2, \dots, T_n$ : o tempo de sobrevida de  $n$  pacientes submetidos a um novo tratamento médico.
- Deseja-se estimar o tempo esperado  $\mathbb{E}(T)$  de sobrevida após o tratamento.
- Simples: tire a média aritmética dos  $n$  tempos observados.
- Suponha que o experimento precisa fornecer uma estimativa um anos após o início do estudo.
- Um ano após o estudo, 50% dos pacientes faleceram (e portanto sabe-se o valor de  $T$  para estes indivíduos).
- Mas 50% ainda não faleceram e não se conhece  $T$  para estes outros indivíduos.

## Mais um exemplo

- Dados  $T_1, T_2, \dots, T_n$ : o tempo de sobrevida de  $n$  pacientes submetidos a um novo tratamento médico.
- Deseja-se estimar o tempo esperado  $\mathbb{E}(T)$  de sobrevida após o tratamento.
- Simples: tire a média aritmética dos  $n$  tempos observados.
- Suponha que o experimento precisa fornecer uma estimativa um anos após o início do estudo.
- Um ano após o estudo, 50% dos pacientes faleceram (e portanto sabe-se o valor de  $T$  para estes indivíduos).
- Mas 50% ainda não faleceram e não se conhece  $T$  para estes outros indivíduos.
- A média dos valores conhecidos vai tender a subestimar o valor esperado de sobrevida.

## Mais um exemplo

- Dados  $T_1, T_2, \dots, T_n$ : o tempo de sobrevida de  $n$  pacientes submetidos a um novo tratamento médico.
- Deseja-se estimar o tempo esperado  $\mathbb{E}(T)$  de sobrevida após o tratamento.
- Simples: tire a média aritmética dos  $n$  tempos observados.
- Suponha que o experimento precisa fornecer uma estimativa um anos após o início do estudo.
- Um ano após o estudo, 50% dos pacientes faleceram (e portanto sabe-se o valor de  $T$  para estes indivíduos).
- Mas 50% ainda não faleceram e não se conhece  $T$  para estes outros indivíduos.
- A média dos valores conhecidos vai tender a subestimar o valor esperado de sobrevida.
- Como fazer neste caso?

# Modelos conceituais

- Precisamos de um *modelo estatístico conceitual*.

# Modelos conceituais

- Precisamos de um *modelo estatístico conceitual*.
- **Modelo Estatístico Conceitual:** Uma distribuição de probabilidade **hipotética** descrevendo como os dados observados **poderiam** ter sido gerados.

# Modelos conceituais

- Precisamos de um *modelo estatístico conceitual*.
- **Modelo Estatístico Conceitual:** Uma distribuição de probabilidade **hipotética** descrevendo como os dados observados **poderiam** ter sido gerados.
- A modelagem é a concepção de um arcabouço matemático capaz de gerar os dados.

# Modelos conceituais

- Precisamos de um *modelo estatístico conceitual*.
- **Modelo Estatístico Conceitual:** Uma distribuição de probabilidade **hipotética** descrevendo como os dados observados **poderiam** ter sido gerados.
- A modelagem é a concepção de um arcabouço matemático capaz de gerar os dados.
- Os dados que nos interessam não são determinísticos.

# Modelos conceituais

- Precisamos de um *modelo estatístico conceitual*.
- **Modelo Estatístico Conceitual:** Uma distribuição de probabilidade **hipotética** descrevendo como os dados observados **poderiam** ter sido gerados.
- A modelagem é a concepção de um arcabouço matemático capaz de gerar os dados.
- Os dados que nos interessam não são determinísticos.
- Assim esse modelo matemático geralmente é um modelo probabilístico ou estocástico.

# Modelos conceituais

- Precisamos de um *modelo estatístico conceitual*.
- **Modelo Estatístico Conceitual:** Uma distribuição de probabilidade **hipotética** descrevendo como os dados observados **poderiam** ter sido gerados.
- A modelagem é a concepção de um arcabouço matemático capaz de gerar os dados.
- Os dados que nos interessam não são determinísticos.
- Assim esse modelo matemático geralmente é um modelo probabilístico ou estocástico.
- Vamos listar algumas das propriedades desejadas de um bom modelo estatístico.

# Propriedades desejadas de um modelo probabilístico

- O modelo probabilístico deve ser capaz de simular dados com características estatísticas semelhantes a aquelas observadas na realidade.

# Propriedades desejadas de um modelo probabilístico

- O modelo probabilístico deve ser capaz de simular dados com características estatísticas semelhantes a aquelas observadas na realidade.
- Por exemplo, deve ser capaz de predizer mais ou menos bem eventos que realmente ocorrem na realidade.

# Propriedades desejadas de um modelo probabilístico

- O modelo probabilístico deve ser capaz de simular dados com características estatísticas semelhantes a aquelas observadas na realidade.
- Por exemplo, deve ser capaz de predizer mais ou menos bem eventos que realmente ocorrem na realidade.
- O modelo propõe um mecanismo plausível, que corresponde em algum sentido ao que realmente acontece na realidade.

# Propriedades desejadas de um modelo probabilístico

- O modelo probabilístico deve ser capaz de simular dados com características estatísticas semelhantes a aquelas observadas na realidade.
- Por exemplo, deve ser capaz de predizer mais ou menos bem eventos que realmente ocorrem na realidade.
- O modelo propõe um mecanismo plausível, que corresponde em algum sentido ao que realmente acontece na realidade.
- Um mecanismo plausível pode sugerir intervenções ou ações que alterem a realidade de alguma maneira desejada (prevenindo doenças e fraudes, por exemplo).

# Propriedades desejadas de um modelo probabilístico

- O modelo probabilístico deve ser capaz de simular dados com características estatísticas semelhantes a aquelas observadas na realidade.
- Por exemplo, deve ser capaz de predizer mais ou menos bem eventos que realmente ocorrem na realidade.
- O modelo propõe um mecanismo plausível, que corresponde em algum sentido ao que realmente acontece na realidade.
- Um mecanismo plausível pode sugerir intervenções ou ações que alterem a realidade de alguma maneira desejada (prevenindo doenças e fraudes, por exemplo).
- Finalmente, o modelo deve ser facilmente manipulável matematicamente e conceitualmente.

# Propriedades desejadas de um modelo probabilístico

- O modelo probabilístico deve ser capaz de simular dados com características estatísticas semelhantes a aquelas observadas na realidade.
- Por exemplo, deve ser capaz de predizer mais ou menos bem eventos que realmente ocorrem na realidade.
- O modelo propõe um mecanismo plausível, que corresponde em algum sentido ao que realmente acontece na realidade.
- Um mecanismo plausível pode sugerir intervenções ou ações que alterem a realidade de alguma maneira desejada (prevenindo doenças e fraudes, por exemplo).
- Finalmente, o modelo deve ser facilmente manipulável matematicamente e conceitualmente.
- Precisamos fazer cálculos de probabilidade com o modelo. Se ele for muito complexo, não seremos capazes disso.

# Propriedades desejadas de um modelo probabilístico

- O modelo probabilístico deve ser capaz de simular dados com características estatísticas semelhantes a aquelas observadas na realidade.
- Por exemplo, deve ser capaz de predizer mais ou menos bem eventos que realmente ocorrem na realidade.
- O modelo propõe um mecanismo plausível, que corresponde em algum sentido ao que realmente acontece na realidade.
- Um mecanismo plausível pode sugerir intervenções ou ações que alterem a realidade de alguma maneira desejada (prevenindo doenças e fraudes, por exemplo).
- Finalmente, o modelo deve ser facilmente manipulável matematicamente e conceitualmente.
- Precisamos fazer cálculos de probabilidade com o modelo. Se ele for muito complexo, não seremos capazes disso.

# As propriedades costumam ser conflitantes

- Muitas vezes, não é possível ter todas as três propriedades simultaneamente.

# As propriedades costumam ser conflitantes

- Muitas vezes, não é possível ter todas as três propriedades simultaneamente.
- Por exemplo, um modelo para gerar dados que sejam bem realistas talvez tenha que se tornar muito complicado.

# As propriedades costumam ser conflitantes

- Muitas vezes, não é possível ter todas as três propriedades simultaneamente.
- Por exemplo, um modelo para gerar dados que sejam bem realistas talvez tenha que se tornar muito complicado.
- Isto significa que ele provavelmente vai ser difícil de analisar matematicamente.

# As propriedades costumam ser conflitantes

- Muitas vezes, não é possível ter todas as três propriedades simultaneamente.
- Por exemplo, um modelo para gerar dados que sejam bem realistas talvez tenha que se tornar muito complicado.
- Isto significa que ele provavelmente vai ser difícil de analisar matematicamente.
- Por isto, pode ser razoável considerar modelos que reproduzem apenas algumas das características dos dados subjacentes.

# As propriedades costumam ser conflitantes

- Muitas vezes, não é possível ter todas as três propriedades simultaneamente.
- Por exemplo, um modelo para gerar dados que sejam bem realistas talvez tenha que se tornar muito complicado.
- Isto significa que ele provavelmente vai ser difícil de analisar matematicamente.
- Por isto, pode ser razoável considerar modelos que reproduzem apenas algumas das características dos dados subjacentes.
- Queremos reproduzir no modelo as principais características em que estamos mais interessados no momento.

# As propriedades costumam ser conflitantes

- Muitas vezes, não é possível ter todas as três propriedades simultaneamente.
- Por exemplo, um modelo para gerar dados que sejam bem realistas talvez tenha que se tornar muito complicado.
- Isto significa que ele provavelmente vai ser difícil de analisar matematicamente.
- Por isto, pode ser razoável considerar modelos que reproduzem apenas algumas das características dos dados subjacentes.
- Queremos reproduzir no modelo as principais características em que estamos mais interessados no momento.
- O processo de modelagem é geralmente difícil, exige experiência, e muitas vezes é uma ciência E uma arte.

# Modelos para quê?

- Por que estamos interessados em elaborar modelos matemáticos para os nossos dados observados?

# Modelos para quê?

- Por que estamos interessados em elaborar modelos matemáticos para os nossos dados observados?
- Um bom modelo dá certo significado aos nossos dados e ajuda a entender de forma aproximada o mecanismo por meio do qual os dados são criados.

# Modelos para quê?

- Por que estamos interessados em elaborar modelos matemáticos para os nossos dados observados?
- Um bom modelo dá certo significado aos nossos dados e ajuda a entender de forma aproximada o mecanismo por meio do qual os dados são criados.
- Muitas vezes, o modelo é apenas uma CARICATURA da situação real.

# Modelos para quê?

- Por que estamos interessados em elaborar modelos matemáticos para os nossos dados observados?
- Um bom modelo dá certo significado aos nossos dados e ajuda a entender de forma aproximada o mecanismo por meio do qual os dados são criados.
- Muitas vezes, o modelo é apenas uma CARICATURA da situação real.
- Caricatura é um desenho de um personagem da vida real que enfatiza e exagera algumas das características físicas ou comportamentais da pessoa de uma forma humorística.

# Modelos para quê?

- Por que estamos interessados em elaborar modelos matemáticos para os nossos dados observados?
- Um bom modelo dá certo significado aos nossos dados e ajuda a entender de forma aproximada o mecanismo por meio do qual os dados são criados.
- Muitas vezes, o modelo é apenas uma CARICATURA da situação real.
- Caricatura é um desenho de um personagem da vida real que enfatiza e exagera algumas das características físicas ou comportamentais da pessoa de uma forma humorística.

# Modelo para rede complexa

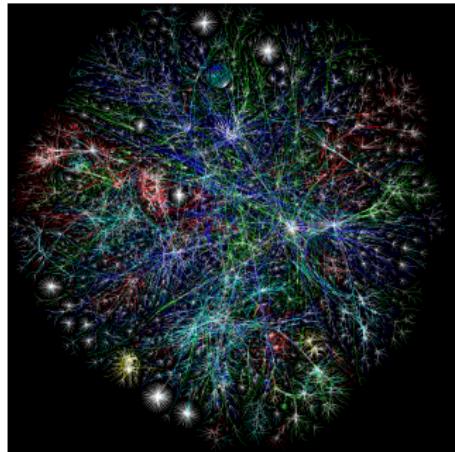
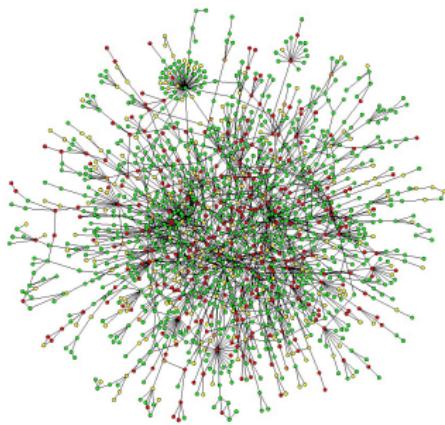
- Redes complexas possuem a maioria dos seus vértices com poucas arestas.

# Modelo para rede complexa

- Redes complexas possuem a maioria dos seus vértices com poucas arestas.
- Entretanto, alguns poucos vértices possuem muitas arestas (são os hubs da rede).

# Modelo para rede complexa

- Redes complexas possuem a maioria dos seus vértices com poucas arestas.
- Entretanto, alguns poucos vértices possuem muitas arestas (são os hubs da rede).



# Modelo para rede complexa

- Seja  $\mathbb{P}(k)$  a probabilidade de um vértice escolhido ao acaso possuir  $k$  arestas.

## Modelo para rede complexa

- Seja  $\mathbb{P}(k)$  a probabilidade de um vértice escolhido ao acaso possuir  $k$  arestas.
- Quase sempre, encontramos em redes complexas que  $\mathbb{P}(k) \approx c/k^\gamma$  onde  $c$  e  $\gamma$  são constantes.

## Modelo para rede complexa

- Seja  $\mathbb{P}(k)$  a probabilidade de um vértice escolhido ao acaso possuir  $k$  arestas.
- Quase sempre, encontramos em redes complexas que  $\mathbb{P}(k) \approx c/k^\gamma$  onde  $c$  e  $\gamma$  são constantes.
- Isto é chamado uma distribuição de probabilidade na forma power-law (potência inversa de  $k$ ).

## Modelo para rede complexa

- Seja  $\mathbb{P}(k)$  a probabilidade de um vértice escolhido ao acaso possuir  $k$  arestas.
- Quase sempre, encontramos em redes complexas que  $\mathbb{P}(k) \approx c/k^\gamma$  onde  $c$  e  $\gamma$  são constantes.
- Isto é chamado uma distribuição de probabilidade na forma power-law (potência inversa de  $k$ ).
- Como isto pode acontecer na prática?

## Modelo para rede complexa

- Seja  $\mathbb{P}(k)$  a probabilidade de um vértice escolhido ao acaso possuir  $k$  arestas.
- Quase sempre, encontramos em redes complexas que  $\mathbb{P}(k) \approx c/k^\gamma$  onde  $c$  e  $\gamma$  são constantes.
- Isto é chamado uma distribuição de probabilidade na forma power-law (potência inversa de  $k$ ).
- Como isto pode acontecer na prática?

# Modelo de Polya-Erdös

- Suponha que cada par de vértices joga uma moeda para o alto com probabilidade  $\theta$  de sair cara.

# Modelo de Polya-Erdös

- Suponha que cada par de vértices joga uma moeda para o alto com probabilidade  $\theta$  de sair cara.
- Se der cara, um link é estabelecido entre eles.

# Modelo de Polya-Erdös

- Suponha que cada par de vértices joga uma moeda para o alto com probabilidade  $\theta$  de sair cara.
- Se der cara, um link é estabelecido entre eles.
- Se der coroa, eles não se ligam.

# Modelo de Polya-Erdös

- Suponha que cada par de vértices joga uma moeda para o alto com probabilidade  $\theta$  de sair cara.
- Se der cara, um link é estabelecido entre eles.
- Se der coroa, eles não se ligam.
- Como veremos mais tarde, o número de links de um nó num grafo com  $n$  vértices segue uma distribuição Binomial  $\text{Bin}(n - 1, \theta)$
- Por mero acaso, alguns vértices terão um número de links maior que outros.

# Modelo de Polya-Erdös

- Suponha que cada par de vértices joga uma moeda para o alto com probabilidade  $\theta$  de sair cara.
- Se der cara, um link é estabelecido entre eles.
- Se der coroa, eles não se ligam.
- Como veremos mais tarde, o número de links de um nó num grafo com  $n$  vértices segue uma distribuição Binomial  $\text{Bin}(n - 1, \theta)$
- Por mero acaso, alguns vértices terão um número de links maior que outros.

# Modelo de Polya-Erdös

- Este modelo de Polya-Erdös não é capaz de gerar a característica power-law vista em grafos reais de redes complexas.

# Modelo de Polya-Erdös

- Este modelo de Polya-Erdös não é capaz de gerar a característica power-law vista em grafos reais de redes complexas.
- O número de links de um vértice tem pouca variação em torno da média.
- Nunca aparecem os hubs dominantes que vemos nos casos reais.

# Modelo de Polya-Erdös

- Este modelo de Polya-Erdös não é capaz de gerar a característica power-law vista em grafos reais de redes complexas.
- O número de links de um vértice tem pouca variação em torno da média.
- Nunca aparecem os hubs dominantes que vemos nos casos reais.
- Este não é um bom modelo para as redes complexas da realidade.

# Modelo de preferential attachment

- O modelo de rede social *preferential-attachment* de Barabási-Albert é uma alternativa.

# Modelo de preferential attachment

- O modelo de rede social *preferential-attachment* de Barabási-Albert é uma alternativa.
- Comece com poucos vértices ligados ao acaso entre si pelo modelo anterior.

# Modelo de preferential attachment

- O modelo de rede social *preferential-attachment* de Barabási-Albert é uma alternativa.
- Comece com poucos vértices ligados ao acaso entre si pelo modelo anterior.
- Introduza novos vértices sequencialmente.

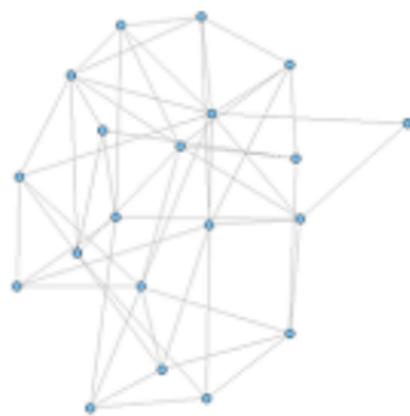
# Modelo de preferential attachment

- O modelo de rede social *preferential-attachment* de Barabási-Albert é uma alternativa.
- Comece com poucos vértices ligados ao acaso entre si pelo modelo anterior.
- Introduza novos vértices sequencialmente.
- Um novo vértice conecta-se a um nó já existente com uma probabilidade proporcional ao número de arestas que o nó antigo já possui.

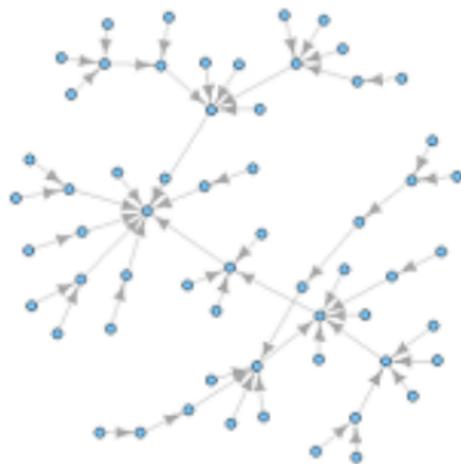
# Modelo de preferential attachment

- O modelo de rede social *preferential-attachment* de Barabási-Albert é uma alternativa.
- Comece com poucos vértices ligados ao acaso entre si pelo modelo anterior.
- Introduza novos vértices sequencialmente.
- Um novo vértice conecta-se a um nó já existente com uma probabilidade proporcional ao número de arestas que o nó antigo já possui.

# Os dois modelos: exemplo de realizações



Random Graph



Preferential Attachment

# Modelo de preferential attachment

- Este não é um modelo perfeito para as redes complexas reais.

# Modelo de preferential attachment

- Este não é um modelo perfeito para as redes complexas reais.
- Mas ele induz uma distribuição nos graus dos vértices de redes complexas que possui uma forma de power-law, com cauda pesada.

# Modelo de preferential attachment

- Este não é um modelo perfeito para as redes complexas reais.
- Mas ele induz uma distribuição nos graus dos vértices de redes complexas que possui uma forma de power-law, com cauda pesada.
- Temos em mãos então um mecanismo hipotético que produz um aspecto muito visível e característico das redes complexas.

# Modelo de preferential attachment

- Este não é um modelo perfeito para as redes complexas reais.
- Mas ele induz uma distribuição nos graus dos vértices de redes complexas que possui uma forma de power-law, com cauda pesada.
- Temos em mãos então um mecanismo hipotético que produz um aspecto muito visível e característico das redes complexas.
- Temos uma caricatura do processo gerador REAL das redes complexas.

# Modelo de preferential attachment

- Este não é um modelo perfeito para as redes complexas reais.
- Mas ele induz uma distribuição nos graus dos vértices de redes complexas que possui uma forma de power-law, com cauda pesada.
- Temos em mãos então um mecanismo hipotético que produz um aspecto muito visível e característico das redes complexas.
- Temos uma caricatura do processo gerador REAL das redes complexas.

# Modelos para quê?

- Outro uso de um bom modelo é fazer previsões.

# Modelos para quê?

- Outro uso de um bom modelo é fazer previsões.
- Um modelo de classificação de risco de crédito serve para isto.

# Modelos para quê?

- Outro uso de um bom modelo é fazer previsões.
- Um modelo de classificação de risco de crédito serve para isto.
- Com base em várias features (características) de um usuário, conseguimos prever se ele vai pagar ou não na data combinada um eventual empréstimo.

# Modelos para quê?

- Outro uso de um bom modelo é fazer previsões.
- Um modelo de classificação de risco de crédito serve para isto.
- Com base em várias features (características) de um usuário, conseguimos prever se ele vai pagar ou não na data combinada um eventual empréstimo.
- Isto é feito com dados históricos: temos uma enorme coleção de indivíduos que tomaram empréstimo e qual foi o resultado ( $Y = 1$ , pagou;  $Y = 0$ , não pagou).

# Modelos para quê?

- Outro uso de um bom modelo é fazer previsões.
- Um modelo de classificação de risco de crédito serve para isto.
- Com base em várias features (características) de um usuário, conseguimos prever se ele vai pagar ou não na data combinada um eventual empréstimo.
- Isto é feito com dados históricos: temos uma enorme coleção de indivíduos que tomaram empréstimo e qual foi o resultado ( $Y = 1$ , pagou;  $Y = 0$ , não pagou).
- Para cada indivíduo, temos também suas características coletadas como um vetor  $x$ .

# Modelos para quê?

- Algumas das características: sexo, idade, tempo como correntista, saldo médio, etc.

# Modelos para quê?

- Algumas das características: sexo, idade, tempo como correntista, saldo médio, etc.
- Com estes dados estatísticos, encontramos um modelo para  $\mathbb{P}(Y = 1|x)$ .

# Modelos para quê?

- Algumas das características: sexo, idade, tempo como correntista, saldo médio, etc.
- Com estes dados estatísticos, encontramos um modelo para  $\mathbb{P}(Y = 1|x)$ .
- Isto é, um modelo para a probab de pagar dado que possui as características x.

# Modelos para quê?

- Algumas das características: sexo, idade, tempo como correntista, saldo médio, etc.
- Com estes dados estatísticos, encontramos um modelo para  $\mathbb{P}(Y = 1|x)$ .
- Isto é, um modelo para a probab de pagar dado que possui as características x.
- Este modelo é usado para predizer o comportamento de futuros tomadores de empréstimo.

# Modelos para quê?

- Algumas das características: sexo, idade, tempo como correntista, saldo médio, etc.
- Com estes dados estatísticos, encontramos um modelo para  $\mathbb{P}(Y = 1|x)$ .
- Isto é, um modelo para a probab de pagar dado que possui as características x.
- Este modelo é usado para predizer o comportamento de futuros tomadores de empréstimo.
- Um cliente com as características x chega e pede um empréstimo.

# Modelos para quê?

- Algumas das características: sexo, idade, tempo como correntista, saldo médio, etc.
- Com estes dados estatísticos, encontramos um modelo para  $\mathbb{P}(Y = 1|x)$ .
- Isto é, um modelo para a probab de pagar dado que possui as características  $x$ .
- Este modelo é usado para predizer o comportamento de futuros tomadores de empréstimo.
- Um cliente com as características  $x$  chega e pede um empréstimo.
- Calcule  $\mathbb{P}(Y = 1|x)$  usando o modelo.

# Modelos para quê?

- Algumas das características: sexo, idade, tempo como correntista, saldo médio, etc.
- Com estes dados estatísticos, encontramos um modelo para  $\mathbb{P}(Y = 1|x)$ .
- Isto é, um modelo para a probab de pagar dado que possui as características  $x$ .
- Este modelo é usado para predizer o comportamento de futuros tomadores de empréstimo.
- Um cliente com as características  $x$  chega e pede um empréstimo.
- Calcule  $\mathbb{P}(Y = 1|x)$  usando o modelo.
- Se a probabilidade é baixa, não conceda o empréstimo.

# Modelos para quê?

- Algumas das características: sexo, idade, tempo como correntista, saldo médio, etc.
- Com estes dados estatísticos, encontramos um modelo para  $\mathbb{P}(Y = 1|x)$ .
- Isto é, um modelo para a probab de pagar dado que possui as características  $x$ .
- Este modelo é usado para predizer o comportamento de futuros tomadores de empréstimo.
- Um cliente com as características  $x$  chega e pede um empréstimo.
- Calcule  $\mathbb{P}(Y = 1|x)$  usando o modelo.
- Se a probabilidade é baixa, não conceda o empréstimo.

# Modelos para quê?

- Tomar decisões...

# Modelos para quê?

- Tomar decisões...
- Conceder o empréstimo?

# Modelos para quê?

- Tomar decisões...
- Conceder o empréstimo?
- Oferecer desconto a cliente se é grande a chance dele comprar um item muito caro.

# Modelos para quê?

- Tomar decisões...
- Conceder o empréstimo?
- Oferecer desconto a cliente se é grande a chance dele comprar um item muito caro.
- Cortar a conexão a uma rede se a chance de que certas atividades na rede sejam ação de hackers.

# Modelos para quê?

- Tomar decisões...
- Conceder o empréstimo?
- Oferecer desconto a cliente se é grande a chance dele comprar um item muito caro.
- Cortar a conexão a uma rede se a chance de que certas atividades na rede sejam ação de hackers.
- Construir uma nova estação metereológica numa localização  $(x, y)$  se esta posição minimiza a incerteza de previsões para a região como um todo a partir da rede existente mais a nova estação.

# Modelos para quê?

- Tomar decisões...
- Conceder o empréstimo?
- Oferecer desconto a cliente se é grande a chance dele comprar um item muito caro.
- Cortar a conexão a uma rede se a chance de que certas atividades na rede sejam ação de hackers.
- Construir uma nova estação metereológica numa localização  $(x, y)$  se esta posição minimiza a incerteza de previsões para a região como um todo a partir da rede existente mais a nova estação.

# Objetivos da disciplina

- Estudar os fundamentos dos modelos estatísticos úteis para análise de dados.

# Objetivos da disciplina

- Estudar os fundamentos dos modelos estatísticos úteis para análise de dados.
- Veremos muitas aplicações e exemplos reais mas a ênfase está nos fundamentos.

# Objetivos da disciplina

- Estudar os fundamentos dos modelos estatísticos úteis para análise de dados.
- Veremos muitas aplicações e exemplos reais mas a ênfase está nos fundamentos.
- Nível de matemática requerido: básico (a esta altura, você já viu a lista 01).

# Objetivos da disciplina

- Estudar os fundamentos dos modelos estatísticos úteis para análise de dados.
- Veremos muitas aplicações e exemplos reais mas a ênfase está nos fundamentos.
- Nível de matemática requerido: básico (a esta altura, você já viu a lista 01).
- Cálculo de várias variáveis: derivada parcial, gradiente, integral múltipla, maximização de  $f(x, y)$ .

# Objetivos da disciplina

- Estudar os fundamentos dos modelos estatísticos úteis para análise de dados.
- Veremos muitas aplicações e exemplos reais mas a ênfase está nos fundamentos.
- Nível de matemática requerido: básico (a esta altura, você já viu a lista 01).
- Cálculo de várias variáveis: derivada parcial, gradiente, integral múltipla, maximização de  $f(x, y)$ .
- Precisamos mais dos conceitos do que da manipulação algébrica exaustiva.

# Objetivos da disciplina

- Estudar os fundamentos dos modelos estatísticos úteis para análise de dados.
- Veremos muitas aplicações e exemplos reais mas a ênfase está nos fundamentos.
- Nível de matemática requerido: básico (a esta altura, você já viu a lista 01).
- Cálculo de várias variáveis: derivada parcial, gradiente, integral múltipla, maximização de  $f(x, y)$ .
- Precisamos mais dos conceitos do que da manipulação algébrica exaustiva.
- Algebra de matrizes: importante, quanto mais você souber, melhor para você, inclusive a manipulação.
- Espero que você já tenha sido exposto a um curso de probabilidade anteriormente: vamos revisar muito rapidamente.

# Livro Texto

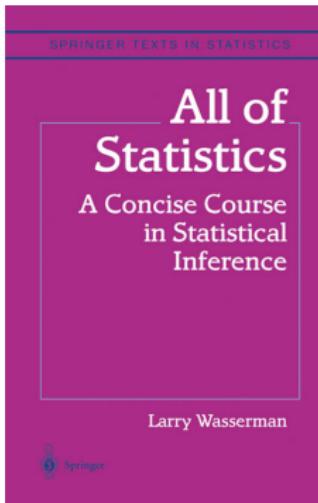
- Vamos seguir dois livros.

## Livro Texto

- Vamos seguir dois livros.
- A primeira parte da disciplina (3 semanas) cobre probabilidade.

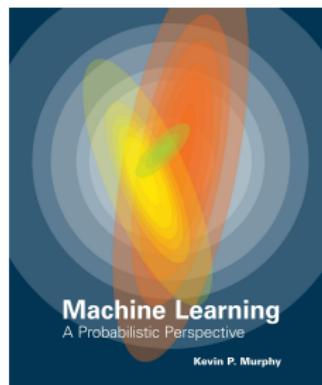
# Livro Texto

- Vamos seguir dois livros.
- A primeira parte da disciplina (3 semanas) cobre probabilidade.
- Vou usar os 5 primeiros capítulos de *All of Statistics*, de Larry Wasserman, do Depto de Machine Learning de Carnegie Mellon.



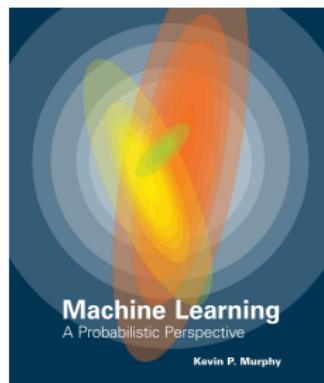
...

- A segunda parte da disciplina vai se basear no livro *Machine Learning, a Probabilistic Approach*, de Kevin Murphy.
- Atualmente, no Google  
<http://research.google.com/pubs/KevinMurphy.html>



...

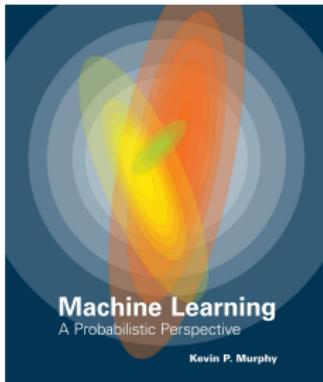
- A segunda parte da disciplina vai se basear no livro *Machine Learning, a Probabilistic Approach*, de Kevin Murphy.
- Atualmente, no Google  
<http://research.google.com/pubs/KevinMurphy.html>



- Vamos cobrir os capítulos integralmente os capítulos: 2, 4, 6, 7, 8, 9.

...

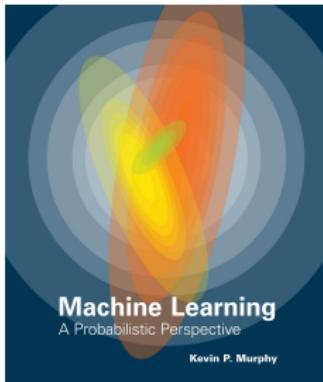
- A segunda parte da disciplina vai se basear no livro *Machine Learning, a Probabilistic Approach*, de Kevin Murphy.
- Atualmente, no Google  
<http://research.google.com/pubs/KevinMurphy.html>



- Vamos cobrir os capítulos integralmente os capítulos: 2, 4, 6, 7, 8, 9.
- Cobriremos parcialmente os capítulos 3 (3.2 e 3.5) , 12 (12.1, 12.2, 12.3), 13 (13.3 e 13.4), 14 (14.2 e 14.3)

...

- A segunda parte da disciplina vai se basear no livro *Machine Learning, a Probabilistic Approach*, de Kevin Murphy.
- Atualmente, no Google  
<http://research.google.com/pubs/KevinMurphy.html>



- Vamos cobrir os capítulos integralmente os capítulos: 2, 4, 6, 7, 8, 9.
- Cobriremos parcialmente os capítulos 3 (3.2 e 3.5) , 12 (12.1, 12.2, 12.3), 13 (13.3 e 13.4), 14 (14.2 e 14.3)

# Avaliação

- Listas de exercícios semanais: 40 pontos ao todo.

# Avaliação

- Listas de exercícios semanais: 40 pontos ao todo.
- Teremos 3 provas de 20 pontos cada.

# Avaliação

- Listas de exercícios semanais: 40 pontos ao todo.
- Teremos 3 provas de 20 pontos cada.
- Prova será SEM consulta.
- Site inicial da disciplina (preciso remontar):  
<http://homepages.dcc.ufmg.br/~assuncao/EstatCC/>
- Site oficial da disciplina: moodle.

# Fundamentos Estatísticos para Ciência dos dados

